

TP — Data Warehouse & BI

Mini Zalando

1. Contexte

Vous avez développé un mini SI e-commerce composé de 3 microservices :


- **catalog-service** : produits, catégories, prix, stock
- **customer-service** : clients, adresses
- **order-service** : commandes, lignes de commande, total, statut

Ce SI est orienté **opérationnel / transactionnel**.

Aujourd'hui, vous allez construire une architecture **Data Warehouse + BI**.

2. Objectif du TP

Mettre en place la chaîne suivante :



L'objectif est de permettre à une direction métier de suivre les ventes, les clients, les produits et les performances commerciales par pays.

3. Étape 1 — Comprendre les données sources

À partir de vos 3 microservices, identifiez les données disponibles.

Questions

- Quelles données sont portées par `catalog-service` ?
 - Quelles données sont portées par `customer-service` ?
 - Quelles données sont portées par `order-service` ?
 - Où trouve-t-on le prix d'un produit ?
 - Où trouve-t-on le pays d'un client ?
 - Où trouve-t-on le montant total d'une commande ?
 - Pourquoi aucune base de données seule ne permet de répondre à toutes les questions BI ?
-

4. Étape 2 — Définir les besoins BI

Vous devez proposer des indicateurs utiles pour piloter l'activité commerciale.

Indicateurs minimum attendus

- Chiffre d'affaires total
- Nombre total de commandes
- Panier moyen
- Nombre de produits vendus
- Top produits vendus
- Chiffre d'affaires par catégorie
- Chiffre d'affaires par client
- Chiffre d'affaires par pays
- Nombre de commandes par pays
- Panier moyen par pays
- Top produits par pays
- Répartition du chiffre d'affaires par pays
- Évolution du chiffre d'affaires dans le temps

Questions

- Quels indicateurs intéressent une direction commerciale ?
 - Quels indicateurs intéressent une équipe marketing ?
 - Quels indicateurs intéressent une équipe logistique ?
 - Quels champs sont nécessaires pour calculer le chiffre d'affaires par pays ?
 - Le pays doit-il venir du client ou de l'adresse de livraison ?
 - Que faire si un client possède plusieurs adresses ?
 - Quelle différence entre "pays du client" et "pays de livraison" ?
 - Quels indicateurs peuvent être calculés uniquement avec `order-service` ?
 - Quels indicateurs nécessitent de croiser plusieurs microservices ?
-

5. Étape 3 — Modéliser le Data Warehouse

Vous devez proposer un modèle décisionnel permettant d'analyser les ventes.

Modèle attendu

Un modèle en étoile.

Table de faits attendue

fact_order_lines

Une ligne = une ligne de commande.

Champs possibles :

- order_id
- order_line_id
- customer_id
- product_id
- category_id
- date_id
- country
- quantity
- unit_price
- line_total
- order_status

Dimensions attendues

dim_customer

- customer_id
- first_name
- last_name
- email
- phone
- is_active
- country
- city

dim_product

- product_id
- product_name
- slug
- category_id

- `category_name`
- `is_active`

`dim_category`

- `category_id`
- `category_name`
- `category_slug`

`dim_date`

- `date_id`
- `date`
- `day`
- `month`
- `month_name`
- `quarter`
- `year`

Questions

- Pourquoi choisir une table de faits basée sur les lignes de commande ?
 - Pourquoi ne pas faire une table de faits avec une ligne par commande uniquement ?
 - Quelle dimension permet l'analyse par pays ?
 - Où stocker le pays : dans `dim_customer`, dans une dimension adresse, ou directement dans la table de faits ?
 - Pourquoi peut-il être utile de copier le pays dans la table de faits ?
 - Pourquoi le modèle décisionnel est-il volontairement différent du modèle transactionnel ?
 - Pourquoi Superset sera plus à l'aise avec ce modèle qu'avec les tables microservices brutes ?
-

6. Étape 4 — Créer le Data Warehouse PostgreSQL

Vous devez créer une nouvelle base PostgreSQL dédiée à l'analyse.

Travail demandé

Créer les tables :

- `fact_order_lines`
- `dim_customer`
- `dim_product`

- `dim_category`
- `dim_date`

Questions

- Pourquoi créer une base PostgreSQL séparée ?
 - Pourquoi ne pas connecter Superset directement aux bases des microservices ?
 - Quels types SQL choisir pour les montants ?
 - Pourquoi éviter les montants en `float` ?
 - Quelles clés primaires et étrangères peut-on définir ?
 - Faut-il imposer toutes les contraintes dans le Data Warehouse ou garder une certaine souplesse ?
-

7. Étape 5 — Coder les pipelines ETL en Python

Vous devez développer un ou plusieurs scripts Python permettant d'alimenter le Data Warehouse.

Extraction

Les données peuvent être extraites :

- soit depuis les APIs REST des microservices ;
- soit directement depuis les bases PostgreSQL des microservices.

Transformation

Le pipeline doit :

- récupérer les commandes ;
- récupérer les lignes de commande ;
- récupérer les produits associés ;
- récupérer les catégories ;
- récupérer les clients ;
- récupérer les adresses ;
- déterminer le pays utilisé pour l'analyse ;
- calculer ou vérifier les montants ;
- préparer les dimensions ;
- préparer la table de faits.

Chargement

Le pipeline doit charger les données dans PostgreSQL Data Warehouse.

Questions

- Quelle méthode d'extraction avez-vous choisie : API ou base SQL ? Pourquoi ?
 - Quels sont les avantages d'une extraction par API ?
 - Quels sont les avantages d'une extraction directe en base ?
 - Quels sont les risques de chaque approche ?
 - Comment gérez-vous les données manquantes ?
 - Que faites-vous si un produit commandé n'existe plus dans le catalogue ?
 - Que faites-vous si un client n'a pas d'adresse ?
 - Comment choisissez-vous le pays lorsqu'un client possède plusieurs adresses ?
 - Comment vérifiez-vous que le total de ligne est correct ?
 - Comment rendez-vous votre script rejouable sans dupliquer les données ?
-

8. Étape 6 — Connecter Apache Superset

Vous devez connecter Apache Superset au Data Warehouse PostgreSQL.

Travail demandé

- Ajouter la connexion PostgreSQL dans Superset
 - Déclarer les datasets nécessaires
 - Créer les graphiques
 - Construire un ou plusieurs dashboards
-

9. Étape 7 — Créer les dashboards BI

Dashboard 1 — Vue globale

Graphiques attendus :

- CA total
- Nombre de commandes
- Nombre de produits vendus
- Panier moyen
- Évolution du CA dans le temps

Dashboard 2 — Analyse produits

Graphiques attendus :

- Top 10 produits par chiffre d'affaires
- Top 10 produits par quantité vendue
- CA par catégorie
- Quantité vendue par catégorie

Dashboard 3 — Analyse clients

Graphiques attendus :

- Top clients par chiffre d'affaires
- Nombre de commandes par client
- Panier moyen par client

Dashboard 4 — Analyse géographique

Graphiques attendus :

- Chiffre d'affaires par pays
- Nombre de commandes par pays
- Panier moyen par pays
- Quantité de produits vendus par pays
- Top produits par pays
- Répartition du CA par pays

Questions BI par pays

- Quel pays génère le plus de chiffre d'affaires ?
 - Quel pays génère le plus grand nombre de commandes ?
 - Le pays avec le plus de commandes est-il aussi celui avec le plus gros panier moyen ?
 - Quels produits se vendent le mieux selon les pays ?
 - Certaines catégories performent-elles mieux dans certains pays ?
 - Y a-t-il des pays avec beaucoup de commandes mais un faible chiffre d'affaires ?
 - Y a-t-il des pays avec peu de commandes mais un panier moyen élevé ?
 - Comment expliquer les différences de performance entre pays ?
-

10. Analyse architecturale finale

Questions

- Pourquoi séparer le SI opérationnel du SI décisionnel ?
 - Pourquoi le Data Warehouse est-il une meilleure source pour Superset ?
 - Pourquoi les microservices ne sont-ils pas adaptés aux requêtes analytiques ?
 - Quelle est la différence entre une base OLTP et une base OLAP ?
 - Quels problèmes avez-vous rencontrés lors du croisement des données ?
 - Quelles incohérences avez-vous détectées ?
 - Quelle donnée a été la plus difficile à intégrer ?
 - Que faudrait-il améliorer pour passer à une architecture data plus industrielle ?
-

11. Livrables attendus

Chaque trinôme doit rendre :

- le code Python des pipelines ETL ;
 - le script SQL de création du Data Warehouse ;
 - un schéma du modèle décisionnel ;
 - les dashboards Superset ;
 - un README expliquant :
 - l'architecture globale ;
 - les sources de données ;
 - le modèle Data Warehouse ;
 - les choix de transformation ;
 - les indicateurs BI ;
 - les limites de la solution.
-

12. Critères d'évaluation

Vous serez évalués sur :

- la compréhension des données sources ;
- la qualité du modèle Data Warehouse ;
- la clarté du pipeline ETL ;
- la cohérence des transformations ;
- la capacité à croiser produits, clients, commandes et pays ;
- la pertinence des dashboards Superset ;
- la qualité de l'analyse architecturale finale.